

BÁO CÁO DỰ ÁN AEGIS: LUMINA

MỤC LỤC

DANH MỤC BẢNG BIỂU, HÌNH ẢNH.....	3
Phụ lục 1: Bảng tóm tắt nguồn dữ liệu.....	4
Phụ lục 2: Cấu hình kỹ thuật hệ thống.....	4
Phụ lục 3: Các chỉ báo kỹ thuật.....	5
Phụ lục 4: Kế hoạch Backup và Disaster Recovery.....	6
Phụ lục 5: Bảng viết tắt và thuật ngữ.....	7
PHẦN 1: NỘI DUNG ĐỒ ÁN.....	8
Tóm tắt báo cáo.....	8
1. Giới thiệu.....	9
2. Mô tả, phân tích tổng quan về dữ liệu.....	10
3. Phương pháp luận nghiên cứu.....	12
3.1 Đóng gói và triển khai hệ thống.....	13
3.2 Tiếp cận kiến trúc Lakehouse và lựa chọn công nghệ.....	14
3.3 Quy trình xử lý nhiều tầng theo kiến trúc Medallion.....	15
3.4 Hệ thống ETL phục vụ cập nhật tự động cho RAG.....	17
3.5 Phân hệ hỏi-đáp thông minh Retrieval-Augmented Generation.....	18
3.6 Điều phối quy trình và quản trị dữ liệu.....	20
4. Thử nghiệm, phân tích và kết quả.....	21
4.1 Kết quả vận hành so với mục tiêu.....	21
4.2 Phân tích kết quả và nhận xét.....	23
4.3 Khuyến nghị và cải thiện.....	24
4.4 Ứng dụng triển khai AEGIS Lumina App.....	24
5. Kết luận.....	25
5.1 Kết luận tổng quát.....	25
5.2 Đóng góp và ưu điểm nổi bật.....	25
5.3 Hạn chế và khuyết điểm.....	26
5.4 Định hướng phát triển.....	26
Danh mục tài liệu tham khảo.....	27

DANH MỤC BẢNG BIỂU, HÌNH ẢNH

Ảnh 1. Sơ đồ tổng quan kiến trúc hệ thống

(Link: https://github.com/lephucchi/finance_portfolio/blob/main/images/diagram.png)

..... 12

Ảnh 2. Dag Airflow tự động lấy dữ liệu cho lớp bronze.

(Link: https://github.com/lephucchi/finance_portfolio/blob/main/images/bronze_layer_pipeline.png)..... 15

Ảnh 3. Dag Airflow tự động xử lý dữ liệu cho lớp silver (Link:

https://github.com/lephucchi/finance_portfolio/blob/main/images/silver_layer_pipeline.png)..... 16

Ảnh 4. Dag Airflow tự động xử lý dữ liệu cho lớp gold(Link:

https://github.com/lephucchi/finance_portfolio/blob/main/images/gold_layer_pipeline.png)..... 17

Ảnh 5. Dag Airflow tự động cập nhật RAG(Link:

https://github.com/lephucchi/finance_portfolio/blob/main/images/gold_layer_pipeline.png)..... 17

Ảnh 6. Flow end to end cho hệ thống hỏi đáp (Link:

<https://drive.google.com/file/d/1F3yMkOACifLeQUmxU22RbIIUlBKybDDF/view?usp=sharing>)..... 19

Ảnh 7. Kiến trúc tổng quan webservices (Link:

<https://drive.google.com/file/d/1uQnjqLNF4WKxYEF2JJpr3Pfi68xlm5Za/view?usp=sharing>)..... 24

Bảng 1. Các thành phần công nghệ chính trong kiến trúc AEGIS Lumina (triển khai trên AWS)..... 10

Bảng 2. Các chỉ số hiệu năng chính của hệ thống AEGIS Lumina trong giai đoạn thí điểm..... 17

Phụ lục 1: Bảng tóm tắt nguồn dữ liệu

Loại dữ liệu	Nguồn	Định dạng gốc	Tần suất cập nhật	Khối lượng trung bình
Giá cổ phiếu (OHLCV)	API thị trường chứng khoán	CSV/JSON	Hàng ngày (phiên giao dịch)	~30 mã × 7 trường/ngày
Tin tức tài chính	6 nguồn báo điện tử chuyên ngành	JSON	Liên tục, cao điểm: vài trăm bài/ngày	200-500 bài/ngày
Chỉ số vĩ mô	Ngân hàng Nhà nước, GSO	CSV/JSON	Tháng/Quý	10-20 chỉ số/tháng
Thông tin doanh nghiệp	Báo cáo tài chính công bố	PDF/JSON	Quý/Năm	~30 công ty × 4 báo cáo/năm

Phụ lục 2: Cấu hình kỹ thuật hệ thống

Thành phần	Phiên bản/Cấu hình	Mục đích sử dụng	Ghi chú
Amazon S3	Standard Storage Class	Lưu trữ tất cả lớp dữ liệu	Versioning enabled, server-side encryption
AWS Glue	Version 4.0	Data Catalog và ETL jobs	Crawler chạy hàng ngày
AWS Athena	Latest	Query engine	Presto-based, serverless
Apache	3.5.0 (PySpark)	Xử lý dữ liệu phân	Chạy trên EMR hoặc Glue

Thành phần	Phiên bản/Cấu hình	Mục đích sử dụng	Ghi chú
Spark		tán	
Apache Airflow	2.7.0	Orchestration	4 DAGs chính (Bronze, Silver, Gold, RAG)
FAISS	1.7.4	Vector database	IndexFlatIP cho độ chính xác cao
Sentence-BERT	Vietnamese model	Text embedding	768-dimensional vectors
Gemini AI	2.0	LLM generation	API-based integration
FastAPI	0.104.0	Backend API	Async support
React	18.2.0	Frontend framework	TypeScript-based
Docker	24.0+	Containerization	Docker Compose cho multi-service
Amazon EC2	t3.large instances	Compute resources	Auto-scaling group

Phụ lục 3: Các chỉ báo kỹ thuật

Chỉ báo	Công thức	Chu kỳ	Ứng dụng
MA (Moving Average)	Trung bình động giá đóng cửa	5, 10, 20, 50, 200 ngày	Xác định xu hướng
RSI (Relative	$RSI = 100 - [100 / (1 + RS)]$,	14 ngày	Đo sức mạnh

Chỉ báo	Công thức	Chu kỳ	Ứng dụng
Strength Index)	$RS = \text{Avg Gain} / \text{Avg Loss}$		tương đối
MACD	$MACD = EMA(12) - EMA(26)$, Signal = EMA(9) của MACD	Hàng ngày	Tín hiệu giao dịch
Bollinger Bands	Upper = $MA + 2 \cdot SD$, Lower = $MA - 2 \cdot SD$	20 ngày	Đo độ biến động
Volume Analysis	So sánh khối lượng với trung bình 20 ngày	Hàng ngày	Xác nhận xu hướng
Volatility	Độ lệch chuẩn của % thay đổi giá	30 ngày	Đánh giá rủi ro

Phụ lục 4: Kế hoạch Backup và Disaster Recovery

Thành phần	Phương pháp backup	Tần suất	Vị trí lưu trữ	RPO	RTO
S3 Bronze data	Cross-region replication	Realtime	us-west-2 (secondary)	< 1 giờ	< 2 giờ
S3 Silver/Gold	Daily snapshot + versioning	Hàng ngày	S3 Glacier	< 24 giờ	< 4 giờ
Glue Catalog	Automated exports to S3	Hàng ngày	us-east-1 backup bucket	< 24 giờ	< 2 giờ
FAISS Index	Daily export to S3	Hàng ngày	Encrypted S3 bucket	< 24 giờ	< 1 giờ

Thành phần	Phương pháp backup	Tần suất	Vị trí lưu trữ	RPO	RTO
Airflow DAGs	Git repository + S3	Mỗi lần thay đổi	GitHub + S3	< 1 giờ	< 30 phút
Database configs	Infrastructure as Code (Terraform)	Mỗi lần thay đổi	Git repository	< 1 giờ	< 1 giờ

Phụ lục 5: Bảng viết tắt và thuật ngữ

Từ viết tắt	Tiếng Anh	Tiếng Việt
AI	Artificial Intelligence	Trí tuệ nhân tạo
BI	Business Intelligence	Phân tích nghiệp vụ
ML	Machine Learning	Học máy
LLM	Large Language Model	Mô hình ngôn ngữ lớn
RAG	Retrieval-Augmented Generation	Sinh văn bản tăng cường truy hồi
ETL	Extract, Transform, Load	Trích xuất, Chuyển đổi, Tải
FAISS	Facebook AI Similarity Search	Tìm kiếm tương tự của Facebook AI
NLP	Natural Language Processing	Xử lý ngôn ngữ tự nhiên
OHLCV	Open, High, Low, Close, Volume	Giá mở, cao, thấp, đóng cửa, khối lượng
SBERT	Sentence-BERT	Mô hình BERT cho câu
SLO	Service Level Objectives	Mục tiêu chất lượng dịch vụ

Từ viết tắt	Tiếng Anh	Tiếng Việt
RPO	Recovery Point Objective	Mục tiêu điểm phục hồi
RTO	Recovery Time Objective	Mục tiêu thời gian phục hồi
P95	95th Percentile	Bách phân vị thứ 95
DAG	Directed Acyclic Graph	Đồ thị có hướng không chu trình
API	Application Programming Interface	Giao diện lập trình ứng dụng
CSV	Comma-Separated Values	Giá trị phân cách bằng dấu phẩy
JSON	JavaScript Object Notation	Ký hiệu đối tượng JavaScript

PHẦN 1: NỘI DUNG ĐỒ ÁN

Tóm tắt báo cáo

Dự án AEGIS Lumina đã xây dựng thành công một nền tảng phân tích tài chính tích hợp trí tuệ nhân tạo (Artificial Intelligence – AI) và phân tích nghiệp vụ (Business Intelligence – BI), với trọng tâm là lĩnh vực ngân hàng và các mã cổ phiếu thuộc nhóm VN30. Hệ thống được triển khai theo mô hình ba tầng Lakehouse (Bronze–Silver–Gold) trên hạ tầng điện toán đám mây Amazon Web Services (AWS), kết hợp quy trình xử lý dữ liệu tuần tự và tiêu chuẩn hóa để đảm bảo chất lượng và khả năng phân tích chuyên sâu. Một điểm nổi bật của hệ thống là tích hợp phân hệ hỏi–đáp thông minh theo hướng kết hợp truy hồi và sinh văn bản (Retrieval-Augmented Generation – RAG). Cơ chế này cho phép người dùng đặt câu hỏi bằng tiếng Việt và nhận được câu trả lời có trích dẫn nguồn đáng tin cậy, nhờ sử dụng thư viện tìm kiếm FAISS (Facebook AI Similarity Search) và mô hình ngôn ngữ lớn Gemini AI. Cơ chế này giúp giảm thiểu hiện tượng bịa thông tin (hallucination) và tăng mức độ tin cậy cho kết quả truy vấn. Đồng thời hệ thống còn xử lý hiệu quả dữ liệu bao gồm giá cổ phiếu, tin tức tài chính tiếng Việt và

các chỉ số kinh tế vĩ mô bằng cách chuyển hóa chúng thành các bảng dữ liệu đặc trưng, phục vụ cho phân tích trực quan (BI) và xây dựng mô hình học máy (Machine Learning – ML). Trong giai đoạn thử nghiệm, thời gian xử lý toàn bộ quy trình dữ liệu từ thu thập đến sẵn sàng phân tích (end-to-end ETL) ở mức bách phân vị thứ 95 (percentile 95 – P95) đạt khoảng 45 phút. Nói cách khác, 95% các lần thực thi pipeline đều hoàn tất trong vòng 45 phút hoặc nhanh hơn, cho thấy mức độ ổn định và hiệu suất cao. Dữ liệu cũng được cập nhật đầy đủ trong vòng bốn giờ sau khi thị trường đóng cửa, đáp ứng các mục tiêu chất lượng dịch vụ (Service Level Objectives – SLO) đã đề ra. Những kết quả này khẳng định tiềm năng ứng dụng thực tế của AEGIS Lumina trong việc hỗ trợ ra quyết định tại các công ty chứng khoán, ngân hàng hoặc tổ chức đầu tư, nơi cần xử lý và phân tích khối lượng thông tin tài chính lớn một cách nhanh chóng và chính xác.

1. Giới thiệu

Ngành dịch vụ tài chính hiện đang vận hành trong bối cảnh khối lượng dữ liệu ngày càng lớn và mức độ dị thể ngày càng phức tạp. Dữ liệu tài chính hiện đại không chỉ bao gồm dữ liệu có cấu trúc như bảng giá và số liệu kế toán, mà còn kết hợp với dữ liệu bán cấu trúc và phi cấu trúc như báo cáo văn bản, tin tức và nội dung từ mạng xã hội. Sự đa dạng này đã làm lộ rõ những giới hạn của các kiến trúc dữ liệu truyền thống vốn thiếu tính linh hoạt khi mở rộng quy mô hoặc tích hợp dữ liệu từ nhiều nguồn khác nhau. Theo Armbrust et al. (2021) và Harby và Zulkernine (2025), mô hình kho dữ liệu truyền thống được tối ưu cho truy vấn SQL nhưng gặp khó khăn trong việc xử lý dữ liệu phi cấu trúc. Ngược lại, mô hình hồ dữ liệu (data lake) tuy linh hoạt về định dạng nhưng lại thiếu khả năng quản trị và hiệu năng truy vấn. Trước thực trạng này, ngành tài chính đang tích cực tìm kiếm các kiến trúc dữ liệu thế hệ mới có thể kết hợp được khả năng lưu trữ linh hoạt với cơ chế quản lý dữ liệu chặt chẽ, đồng thời hỗ trợ phân tích thời gian thực một cách hiệu quả.

Bên cạnh sự phát triển của kiến trúc dữ liệu, các mô hình ngôn ngữ lớn (Large Language Models – LLM) cũng đang mở ra các phương thức tương tác và phân tích mới, cho phép máy tính có thể trả lời câu hỏi và tóm tắt thông tin phức tạp. Tuy nhiên, khi áp dụng trong lĩnh vực tài chính vốn yêu cầu độ chính xác cao, LLM đang gặp trở ngại lớn do hiện tượng “hallucination” – tức là mô hình có thể tạo ra những nội dung có vẻ hợp lý nhưng

thực chất lại không đúng với dữ kiện thực tế. Các nghiên cứu gần đây cho thấy rằng việc tích hợp cơ chế truy hồi thông tin trước khi sinh câu trả lời, tức theo phương pháp Retrieval-Augmented Generation (RAG), có thể giúp mô hình “bám” vào sự thật, từ đó giảm thiểu khả năng sinh ra nội dung sai lệch (Iaroshev et al., 2024; Choe et al., 2025). Cụ thể, trong các hệ thống hỏi–đáp liên quan đến báo cáo tài chính, RAG cho thấy độ tin cậy cao hơn hẳn so với các mô hình sinh thông thường. Bên cạnh đó, kỹ thuật truy hồi phân cấp kết hợp với cơ chế chọn lọc bằng chứng còn giúp tăng độ bao phủ nội dung chính xác và giảm thiểu hiện tượng lặp lại thông tin dư thừa trong các tài liệu tài chính định dạng chuẩn.

AEGIS Lumina được xây dựng như một nghiên cứu tình huống (case study) nhằm giải quyết đồng thời hai thách thức nêu trên trong bối cảnh thị trường tài chính Việt Nam. Mục tiêu chính của dự án là phát triển một quy trình dữ liệu tự động có khả năng mở rộng, từ thu thập đến xử lý và tổng hợp dữ liệu tài chính dị thể bao gồm giá cổ phiếu nhóm ngân hàng và VN30, tin tức tiếng Việt và các chỉ số kinh tế vĩ mô. Tất cả dữ liệu được hợp nhất trong một kiến trúc dữ liệu hiện đại theo mô hình Lakehouse, cho phép thực hiện truy vấn và phân tích từ một nguồn dữ liệu duy nhất. Song song, hệ thống tích hợp phân hệ hỏi–đáp dựa trên RAG để cung cấp câu trả lời có trích dẫn nguồn cho người dùng cuối, qua đó gia tăng độ tin cậy và khả năng kiểm chứng thông tin được sử dụng trong các quyết định tài chính. Báo cáo này sẽ trình bày chi tiết quá trình thiết kế và kết quả triển khai hệ thống AEGIS Lumina. Cấu trúc báo cáo gồm các phần sau: Mục 2 giới thiệu tổng quan về tập dữ liệu đầu vào và cách thức tổ chức dữ liệu; Mục 3 trình bày phương pháp luận và kiến trúc hệ thống đề xuất; Mục 4 phân tích kết quả thực nghiệm và ứng dụng triển khai; và cuối cùng, Mục 5 đưa ra kết luận với các đóng góp chính, hạn chế còn tồn tại và định hướng phát triển trong tương lai.

2. Mô tả, phân tích tổng quan về dữ liệu

Dự án AEGIS Lumina tập trung vào dữ liệu liên quan đến thị trường chứng khoán Việt Nam, đặc biệt là nhóm cổ phiếu ngành ngân hàng và các mã thuộc rổ VN30. Dữ liệu được thu thập từ ba nguồn chính. Thứ nhất là dữ liệu giá cổ phiếu, bao gồm các bảng thời gian thể hiện các thông số như giá mở cửa, giá cao nhất, giá thấp nhất, giá đóng cửa và khối lượng giao dịch (OHLCV). Bên cạnh đó là các thông tin bổ trợ như số lượng cổ

phiếu đang lưu hành và giá trị vốn hóa thị trường cho từng mã cổ phiếu. Dữ liệu này được cập nhật theo từng phiên giao dịch hàng ngày. Thứ hai là tin tức tài chính tiếng Việt, được tổng hợp từ khoảng sáu nguồn tin uy tín trong lĩnh vực tài chính và chứng khoán như báo điện tử và các trang chuyên ngành. Loại dữ liệu này có dạng phi cấu trúc, tức là văn bản tự do, mang lại ngữ cảnh thời sự cho những biến động của thị trường. Thứ ba là các chỉ báo kinh tế vĩ mô, bao gồm các chuỗi số liệu như lãi suất ngân hàng, tỷ lệ lạm phát, tỷ giá ngoại tệ và các chỉ số kinh tế tổng hợp. Các chỉ báo này thường được công bố định kỳ theo tháng hoặc quý và phạm vi lựa chọn tập trung vào những yếu tố có ảnh hưởng trực tiếp đến ngành ngân hàng cũng như toàn thị trường chứng khoán Việt Nam.


Dữ liệu đầu vào có đặc điểm dị thể cao, kết hợp giữa số liệu chuỗi thời gian và văn bản ngôn ngữ tự nhiên. Trong giai đoạn thu thập ban đầu, dữ liệu được lưu trữ tại tầng Bronze dưới định dạng gốc như JSON cho tin tức hoặc CSV cho giá cổ phiếu và chỉ số kinh tế. Việc giữ nguyên định dạng ban đầu giúp đảm bảo khả năng truy vết và phản ánh trung thực sự phân bố cũng như tần suất tự nhiên của dữ liệu như được đề cập trong Armbrust et al. (2021). Ví dụ, dữ liệu giá cổ phiếu có tần suất giao dịch mỗi ngày trong tuần, trong khi tin tức được thu thập liên tục và có mức độ biến động theo thời điểm, trung bình lên đến hàng trăm bản tin mỗi ngày vào thời điểm cao điểm. Dữ liệu vĩ mô có tần suất thấp hơn, thường là hàng tháng hoặc hàng quý, nhưng lại thể hiện ảnh hưởng lâu dài. Sự đa dạng và không đồng đều về tần suất cập nhật đòi hỏi hệ thống lưu trữ phải có tính linh hoạt cao và khả năng xử lý dữ liệu ở quy mô lớn.

Để tổ chức dữ liệu hiệu quả và hỗ trợ phân tích, AEGIS Lumina áp dụng mô hình nhiều tầng theo kiến trúc Medallion nhằm nâng cao dần chất lượng dữ liệu. Tại tầng Silver, dữ liệu từ Bronze được làm sạch và chuẩn hóa. Các bản ghi bị trùng lặp hoặc lỗi được loại bỏ. Định dạng và kiểu dữ liệu cũng được đồng bộ hóa, chẳng hạn chuẩn hóa mã cổ phiếu hoặc định dạng ngày giờ. Ngoài ra, hệ thống còn tính toán thêm các đặc trưng bổ sung để phục vụ phân tích chuyên sâu. Cụ thể, với dữ liệu giá cổ phiếu, hệ thống tính toán các chỉ báo kỹ thuật quan trọng như đường trung bình động (Moving Average – MA), chỉ số sức mạnh tương đối (Relative Strength Index – RSI) và dao động phân kỳ hội tụ trung bình động (Moving Average Convergence Divergence – MACD) cho từng mã theo từng ngày. Đối với dữ liệu văn bản như tin tức, hệ thống áp dụng chuỗi bước xử lý ngôn ngữ

tự nhiên (Natural Language Processing – NLP) như tách từ, trích xuất từ khóa và phân tích cảm xúc (sentiment analysis) để định lượng mức độ tích cực, trung tính hoặc tiêu cực của thông tin theo từng ngày. Tất cả dữ liệu đã xử lý ở tầng Silver được lưu trữ ở định dạng cột (Parquet) đã nén và phân vùng theo ngày trên hệ thống lưu trữ S3 nhằm phục vụ các truy vấn nhanh chóng và tiết kiệm tài nguyên.

Tại tầng Gold, hệ thống tiến hành tổng hợp và làm giàu dữ liệu để tạo ra các bảng chỉ số đặc trưng phục vụ trực tiếp cho phân tích trực quan (BI) và xây dựng mô hình học máy (ML). Ví dụ, hệ thống tổng hợp hiệu suất theo từng nhóm ngành như ngành ngân hàng theo từng ngày và tính toán các chỉ số như tỷ suất sinh lợi trung bình và độ biến động. Ngoài ra, chỉ số tâm lý thị trường cũng được xây dựng bằng cách lấy trung bình điểm sentiment của tất cả tin tức trong ngày, qua đó phản ánh quan điểm thị trường trong từng thời điểm. Các bảng dữ liệu ở tầng Gold cung cấp cái nhìn toàn diện về thị trường từ cả góc độ kỹ thuật như giá và khối lượng giao dịch, đến khía cạnh tâm lý như tin tức và phản ứng của thị trường. Người dùng có thể trực quan hóa các xu hướng và sự phân bố dữ liệu thông qua giao diện dashboard BI, chẳng hạn như biểu đồ so sánh xu hướng sentiment và giá cổ phiếu theo thời gian. Tóm lại, từ dữ liệu thô ban đầu, hệ thống đã tổ chức và biến đổi dữ liệu thành định dạng có cấu trúc, cô đọng và phù hợp cho việc khai thác thông tin. Quy trình xử lý dữ liệu được thiết kế để chạy định kỳ mỗi ngày ngay sau khi thị trường chứng khoán đóng cửa, đảm bảo dữ liệu được cập nhật kịp thời với độ trễ dưới bốn giờ.

3. Phương pháp luận nghiên cứu



Ảnh 1. Sơ đồ tổng quan kiến trúc hệ thống

(Link: https://github.com/lephucchi/finance_portfolio/blob/main/images/diagram.png)

3.1 Đóng gói và triển khai hệ thống

Việc triển khai AEGIS Lumina được thiết kế để bảo đảm linh hoạt, mở rộng thuận lợi và vận hành đơn giản trong môi trường điện toán đám mây. Dự án áp dụng container hóa bằng Docker nhằm thống nhất quá trình đóng gói giữa các môi trường phát triển, thử nghiệm và sản xuất. Mỗi thành phần của hệ thống được đóng gói thành một Docker container độc lập, bao gồm pipeline ETL, dịch vụ API, mô hình ngôn ngữ lớn (Large Language Model), và dashboard giao diện. Cách tiếp cận này tăng tính tái lập, giảm phụ thuộc nền tảng và hỗ trợ kiểm thử phiên bản hiệu quả.

Quy trình triển khai chính thức thực hiện trên Amazon EC2. Một nhóm EC2 instance được cấu hình để lưu trữ và vận hành các container thông qua Docker Compose trong giai đoạn hiện tại và sẵn sàng nâng cấp lên Amazon ECS trong tương lai. Hệ thống sử dụng Security Groups để kiểm soát truy cập, đồng thời gắn IAM Role phù hợp cho từng instance để phân quyền an toàn với các tài nguyên AWS như S3, Glue và Athena. Các script khởi động container được tự động hóa bằng shell script hoặc Terraform, giúp quản trị viên thao tác triển khai chỉ với một bước đơn lẻ. Chiến lược này bảo đảm vận hành ổn định trong môi trường thực tế, đồng thời duy trì khả năng mở rộng theo nhu cầu và dễ dàng tích hợp quy trình CI/CD trong các giai đoạn phát triển tiếp theo.

3.2 Tiếp cận kiến trúc Lakehouse và lựa chọn công nghệ

Để đáp ứng yêu cầu linh hoạt về dữ liệu và hiệu năng phân tích, dự án lựa chọn kiến trúc Data Lakehouse, một thể hệ kiến trúc dữ liệu hợp nhất mới xuất hiện trong những năm gần đây. Lakehouse kết hợp ưu điểm của Data Warehouse về quản trị dữ liệu chặt chẽ và truy vấn SQL hiệu năng cao với ưu điểm của Data Lake về lưu trữ linh hoạt, chi phí thấp và hỗ trợ dữ liệu phi cấu trúc (Armbrust et al., 2021). Về nguyên tắc, Lakehouse cho phép lưu toàn bộ dữ liệu gốc trên hệ thống file hoặc Hadoop dưới định dạng mở, đồng thời bổ sung lớp giao dịch bảo đảm tính nhất quán ACID và khả năng tiền hóa lược đồ như kho dữ liệu truyền thống (Harby & Zulkernine, 2025). Nhờ vậy, tổ chức có thể thực hiện phân tích BI và triển khai học máy trực tiếp trên cùng một nguồn dữ liệu duy

nhất mà không cần di chuyển giữa nhiều hệ thống.

Trong AEGIS Lumina, Lakehouse được hiện thực hóa theo mô hình cloud-native trên AWS. Dữ liệu được lưu trữ tập trung trên Amazon S3 để tận dụng khả năng mở rộng linh hoạt và chi phí hợp lý. AWS Glue được dùng làm data catalog để quản lý lược đồ và siêu dữ liệu cho các lớp Bronze, Silver và Gold, đồng thời cung cấp không gian tên thống nhất cho truy vấn. AWS Athena đóng vai trò SQL query engine không máy chủ, cho phép truy vấn trực tiếp dữ liệu trên S3 thông qua Glue Catalog. Sự kết hợp S3, Glue và Athena phản ánh mẫu triển khai Lakehouse phổ biến, mang lại trải nghiệm “kho dữ liệu trên hồ dữ liệu” với hiệu năng phù hợp. Bên cạnh đó, Apache Spark thông qua PySpark chịu trách nhiệm xử lý phân tán các tác vụ ETL quy mô lớn, còn Apache Airflow điều phối pipeline tổng thể. Hệ thống cũng sử dụng FastAPI để triển khai API phục vụ hỏi đáp thời gian thực, FAISS làm cơ sở dữ liệu vector cho truy vấn tương tự phục vụ RAG (Johnson et al., 2019; Douze et al., 2024), và mô hình ngôn ngữ lớn Gemini 2.0 làm thành phần sinh đáp án.

Bảng 1. Các thành phần công nghệ chính trong kiến trúc AEGIS Lumina (triển khai trên AWS)


Thành phần	Chức năng	Mô tả cụ thể trong hệ thống AEGIS Lumina
Lưu trữ Lakehouse	Lưu trữ dữ liệu thô và đã xử lý	Amazon S3, phân vùng theo ngày, định dạng JSON và Parquet
Catalog & Metadata	Quản lý lược đồ, siêu dữ liệu	AWS Glue Data Catalog, quản lý bảng Bronze, Silver, Gold
Truy vấn dữ liệu	Truy vấn SQL trực tiếp trên lake	AWS Athena, truy vấn không máy chủ trên S3 thông qua Glue
Xử lý dữ liệu song song	Xử lý ETL quy mô lớn	Apache Spark với PySpark cho dữ liệu lớn, Pandas cho tác vụ nhỏ
Điều phối quy trình	Orchestration và Scheduling	Apache Airflow, DAG điều phối pipeline Bronze → Silver → Gold → RAG

Thành phần	Chức năng	Mô tả cụ thể trong hệ thống AEGIS Lumina
Dịch vụ AI hỏi-đáp	Mô hình ngôn ngữ lớn và Vector DB	FAISS IndexFlatIP, Gemini 2.0 sinh câu trả lời có trích dẫn
API & Giao diện	Cung cấp dịch vụ thời gian thực	FastAPI cho API hỏi-đáp và backend, React + TypeScript cho giao diện web
Chất lượng & Bảo mật	Đảm bảo chất lượng và an toàn	Great Expectations, AWS KMS và Secrets Manager, RBAC tối thiểu

3.3 Quy trình xử lý nhiều tầng theo kiến trúc Medallion

Kiến trúc dữ liệu tuân theo mẫu hình Medallion với ba tầng Bronze, Silver và Gold nhằm nâng dần chất lượng và giá trị thông tin qua mỗi bước (Armbrust et al., 2021). Cách tiếp cận nhiều tầng giúp bảo toàn dữ liệu gốc ở Bronze, tinh lọc ở Silver và tổng hợp thành tri thức ở Gold để phục vụ trực tiếp phân tích và ra quyết định (Harby & Zulkernine, 2025).

Tầng Bronze, dữ liệu thô




Ảnh 2. Dag Airflow tự động lấy dữ liệu cho lớp bronze.

(Link: https://github.com/lephucchi/finance_portfolio/blob/main/images/bronze_layer_pipeline.png)

Tầng này tiếp nhận dữ liệu gốc từ các nguồn đầu vào. Dữ liệu giá cổ phiếu, tin tức và chỉ số vĩ mô được ghi thẳng lên S3 theo định dạng nguyên bản như JSON cho văn bản và CSV cho dữ liệu dạng bảng. Mục tiêu là hình thành kho lưu trữ lịch sử bất biến, giữ đầy đủ chi tiết và bảo đảm khả năng truy xuất nguồn gốc. Airflow kích hoạt các tác vụ Bronze theo lịch hằng ngày và lặp lại khi gặp lỗi mạng để duy trì tính cập nhật.

Tầng Silver, dữ liệu tinh lọc




Ảnh 3. Dag Airflow tự động xử lý dữ liệu cho lớp silver (Link:

https://github.com/lephucchi/finance_portfolio/blob/main/images/silver_layer_pipeline.png)

Dữ liệu từ Bronze được làm sạch, chuẩn hóa và bổ sung đặc trưng. Các bước gồm loại trừ trùng lặp, xử lý thiếu, đồng bộ kiểu dữ liệu theo lược đồ Glue. Hệ thống tính các chỉ báo kỹ thuật như MA, RSI và MACD cho chuỗi giá. Với tin tức, hệ thống áp dụng NLP gồm tách từ, trích xuất từ khóa và phân tích cảm xúc. Kết quả được lưu dưới dạng Parquet nén Snappy và phân vùng theo ngày giao dịch để tối ưu truy vấn Athena.

Tầng Gold, dữ liệu tổng hợp




Ảnh 4. Dag Airflow tự động xử lý dữ liệu cho lớp gold(Link:

https://github.com/lephucchi/finance_portfolio/blob/main/images/gold_layer_pipeline.png)

Tầng Gold cung cấp bảng dữ liệu giá trị cao cho BI và ML. Hệ thống tổng hợp hiệu suất ngành ngân hàng theo ngày, tính tỷ suất sinh lợi trung bình và độ biến động. Chỉ số tâm lý thị trường được xây dựng từ điểm cảm xúc trung bình của tin tức theo ngày. Dữ liệu vĩ mô được liên kết với giá cổ phiếu để tạo bảng đặc trưng đa biến. Tất cả bảng Gold được đăng ký vào Glue Catalog và sẵn sàng cho truy vấn tự phục vụ hoặc tích hợp công cụ BI và môi trường học máy. Cách tổ chức này giúp duy trì một phiên bản sự thật duy nhất, tránh sai lệch giữa các phòng ban.

3.4 Hệ thống ETL phục vụ cập nhật tự động cho RAG



Ảnh 5. Dag Airflow tự động cập nhật RAG(Link:


https://github.com/lephucchi/finance_portfolio/blob/main/images/gold_layer_pipeline.png)

Để bảo đảm hệ thống hỏi đáp Retrieval-Augmented Generation luôn sử dụng dữ liệu mới nhất, dự án triển khai một ETL chuyên biệt tự động hóa chu trình thu thập, xử lý và lập chỉ mục nội dung văn bản. Hệ thống vận hành song song với pipeline Bronze, Silver

và Gold nhưng tập trung vào dữ liệu văn bản như tin tức tài chính, báo cáo và tài liệu phi cấu trúc. Quy trình gồm ba giai đoạn.

- **Extract.** Tác vụ Airflow theo lịch hằng ngày quét các nguồn đầu vào như API tin tức và RSS để trích xuất bài viết mới chưa có trong kho.
- **Transform.** Văn bản được chuẩn hóa như loại bỏ HTML và chuẩn mã Unicode, tách câu, loại bỏ từ dừng và gán nhãn metadata gồm thời gian, lĩnh vực và mã ngành liên quan. Sau đó hệ thống mã hóa các đoạn văn thành vector bằng Vietnamese SBERT.
- **Load.** Vector được nạp vào chỉ mục FAISS cùng với metadata như tiêu đề, ngày và nguồn để phục vụ truy xuất. Việc cập nhật có thể thực hiện trực tiếp nếu FAISS chạy trong bộ nhớ hoặc tái lập chỉ mục theo lô khi lưu trữ trên đĩa. Hệ thống thiết lập ngưỡng kiểm thử chất lượng cho nội dung mới để loại bỏ dữ liệu nhiễu và không liên quan. Nhờ cơ chế này, phân hệ RAG luôn phản ánh nội dung mới từ thị trường, đồng bộ giữa vector nhúng và chỉ mục FAISS, đồng thời duy trì hiệu năng trả lời trong bối cảnh thông tin thay đổi nhanh.

3.5 Phân hệ hỏi-đáp thông minh Retrieval-Augmented Generation



Ảnh 6. Flow end to end cho hệ thống hỏi đáp (Link:

<https://drive.google.com/file/d/1F3yMkOACifLeQUmxU22RbIIUlBKybDDF/view?usp=sharing>)

Phân hệ hỏi đáp giúp người dùng truy vấn thông tin tài chính bằng tiếng Việt một cách chính xác và có thể kiểm chứng. Thay vì chỉ dựa vào mô hình sinh, hệ thống truy hỏi bằng chứng liên quan từ kho tri thức trước khi tạo câu trả lời. Cách tiếp cận này được ghi nhận là cải thiện độ xác thực trong các hệ hỏi đáp tài chính (Iaroshev et al., 2024; Choe et al., 2025). Tổng quan quy trình gồm nhiều giai đoạn.

- **Nhúng câu hỏi.** Câu hỏi tiếng Việt được mã hóa thành vector 768 chiều bằng Vietnamese SBERT.
- **Truy hỏi thông tin.** Vector câu hỏi được dùng để tìm các đoạn tài liệu liên quan nhất trong kho tri thức bằng FAISS. Trong phiên bản pilot, hệ thống sử dụng chỉ mục IndexFlatIP để tính toán tương tự chính xác trên toàn bộ vector, bảo đảm độ đúng đắn

cao (Douze et al., 2024). Hệ thống lấy top k ứng viên phù hợp.

- **Xếp hạng lại.** Các đoạn ứng viên được đánh giá lại bằng cross-encoder để chấm điểm mức phù hợp ngữ nghĩa với câu hỏi, sau đó sắp xếp lại thứ tự nhằm ưu tiên bằng chứng sát nhất. Cách làm nhiều tầng này đã cho thấy hiệu quả trong bối cảnh tài chính phức tạp (Choe et al., 2025).
- **Sinh câu trả lời.** Các đoạn đã xếp hạng được đưa vào prompt cùng câu hỏi để Gemini 2.0 sinh câu trả lời cuối bằng tiếng Việt, kèm trích dẫn nguồn. Toàn bộ quy trình có độ trễ khoảng 2 đến 5 giây, bảo đảm trải nghiệm tương tác thời gian thực.
- Cách tiếp cận RAG giúp bảo đảm khả năng truy nguyên về nguồn, tăng mức tin cậy của thông tin cung cấp cho người dùng và giảm xác suất chấp nhận thông tin sai trong thực nghiệm độc lập (Iaroshev et al., 2024; Choe et al., 2025).

3.6 Điều phối quy trình và quản trị dữ liệu

Điều phối ETL: Apache Airflow đóng vai trò xương sống điều phối ETL theo sơ đồ DAG thống nhất. Một DAG chính thực thi tuần tự các pipeline Bronze, Silver, Gold và RAG theo lịch, ví dụ vào 17 giờ hằng ngày sau khi thị trường đóng cửa. Airflow theo dõi trạng thái và tự động retry khi gặp lỗi tạm thời bằng cơ chế backoff. Hệ thống thiết lập cảnh báo qua email hoặc chat khi một tác vụ thất bại nhiều lần để nhóm kỹ thuật kịp thời can thiệp. Các tác vụ Spark được thực thi trên Amazon EMR hoặc AWS Glue ETL jobs khi cần mở rộng xử lý dữ liệu lớn, còn tác vụ nhẹ sử dụng Python và Pandas trên worker của Airflow để tối ưu chi phí và hiệu năng.

Quản trị chất lượng dữ liệu: Dự án áp dụng data contract để quy định lược đồ và ràng buộc chất lượng ở mỗi tầng. Ví dụ, bảng giá cổ phiếu ở Silver phải có đủ các cột OHLCV và không được chứa giá trị thiếu tại cột giá đóng cửa. Bảng sentiment ở Gold phải tổng hợp từ số lượng tin tức tối thiểu để bảo đảm độ tin cậy thống kê. Great Expectations được tích hợp vào pipeline để tự động kiểm thử chất lượng sau mỗi bước ETL. Trường hợp kiểm thử không đạt, dữ liệu sẽ bị cô lập thay vì đưa tiếp sang Gold. Trong giai đoạn pilot, tỷ lệ lô dữ liệu vượt qua toàn bộ kiểm thử chất lượng đạt 100%, phản ánh tính ổn định của pipeline.

Bảo mật và tuân thủ: Hệ thống tuân thủ nguyên tắc ít đặc quyền nhất. Tài khoản IAM

của Airflow chỉ có quyền ghi vào các bucket S3 liên quan. Người dùng phân tích chỉ có quyền đọc dữ liệu Gold qua Athena. Dữ liệu trên S3 được mã hóa bằng SSE-KMS. Mật khẩu và khóa API được quản lý tập trung qua AWS Secrets Manager và không xuất hiện trong mã nguồn. Hệ thống chỉ thu thập dữ liệu thị trường công khai nên không chứa thông tin nhận diện cá nhân. Các bucket S3 bật versioning để phòng ngừa mất mát do thao tác nhầm. Sao lưu định kỳ và sao chép chéo vùng được thiết lập cho lớp dữ liệu quan trọng. Kế hoạch khôi phục thảm họa đặt mục tiêu RPO không vượt quá 24 giờ và RTO không vượt quá 4 giờ, phù hợp chuẩn vận hành trong lĩnh vực tài chính và bảo đảm tính liên tục của hoạt động.

Có thể thấy, phương pháp luận của AEGIS Lumina kết hợp kiến trúc Lakehouse linh hoạt, quy trình ETL nhiều tầng được kiểm soát, hệ thống RAG có trích dẫn và cơ chế triển khai hiện đại. Sự phối hợp chặt chẽ giữa thu thập, lưu trữ, xử lý dữ liệu quy mô lớn và AI trong một nền tảng thống nhất tạo nền tảng cho các phân tích tài chính chính xác và kịp thời, đồng thời duy trì mức độ tin cậy và an toàn dữ liệu ở tiêu chuẩn doanh nghiệp.

4. Thử nghiệm, phân tích và kết quả

4.1 Kết quả vận hành so với mục tiêu

Hệ thống AEGIS Lumina đã được triển khai thử nghiệm và theo dõi các chỉ số hiệu năng then chốt để đối chiếu với SLO đã đặt ra. Bảng dưới đây tổng hợp các chỉ số vận hành chủ chốt ở giai đoạn thí điểm. Tất cả độ trễ đều tính theo bách phân vị 95 để loại trừ các ngoại lệ bất thường.

Bảng 2. Các chỉ số hiệu năng chính của hệ thống AEGIS Lumina trong giai đoạn thí điểm

Chỉ số	Định nghĩa (Mục tiêu SLO)	Kết quả thí điểm
Độ trễ tầng Bronze	Thời gian thu thập và lưu trữ dữ liệu thô mỗi phiên, P95. Mục tiêu: không quá 15 phút	≈ 12 phút
Độ trễ tầng Silver	Thời gian xử lý, làm sạch và xuất dữ liệu Silver, P95. Mục tiêu: không quá 15 phút	≈ 8 phút

Chỉ số	Định nghĩa (Mục tiêu SLO)	Kết quả thí điểm
Độ trễ tầng Gold	Thời gian tổng hợp và ghi bảng Gold, P95. Mục tiêu: không quá 20 phút	$\approx$ 15 phút
Độ trễ cập nhật RAG	Thời gian cập nhật chỉ mục FAISS cho kiến thức mới, P95. Mục tiêu: không quá 15 phút	$\approx$ 10 phút
Độ trễ ETL end-to-end	Thời gian từ khi bắt đầu Bronze đến khi hoàn tất Gold, P95. Mục tiêu: không quá 60 phút	khoảng 45 phút
Độ trễ trả lời RAG	Thời gian chatbot phản hồi từ lúc hỏi đến khi nhận đủ câu trả lời	2–5 giây
Độ mới của dữ liệu	Thời gian từ khi thị trường đóng cửa đến khi dữ liệu Gold sẵn sàng, tối đa. Mục tiêu: nhỏ hơn 4 giờ	Được cập nhật sau 4 giờ khi thị trường đóng cửa
Tỷ lệ thành công pipeline	Tỷ lệ pipeline hoàn thành mỗi tuần không lỗi. Mục tiêu: từ 95 phần trăm trở lên	khoảng 98 phần trăm mỗi tuần
Tỷ lệ kiểm thử DQ đạt	Tỷ lệ lô dữ liệu vượt qua toàn bộ kiểm thử chất lượng dữ liệu	100 phần trăm

Ghi chú. Ký hiệu $\approx$ biểu thị giá trị xấp xỉ trung bình quan sát.

Kết quả cho thấy hệ thống đáp ứng và nhiều chỉ tiêu vượt SLO. Tổng thời gian ETL từ thu thập đến hoàn tất lớp Gold ở mức khoảng 45 phút theo P95, nhanh hơn đáng kể so với mục tiêu 60 phút nên dữ liệu phân tích sẵn sàng sớm sau giờ giao dịch. Tầng Bronze mất khoảng 12 phút mỗi phiên bao gồm gọi API giá và thu thập vài trăm tin tức. Tầng Silver mất khoảng 8 phút nhờ khả năng song song của Spark. Tầng Gold mất khoảng 15 phút để tổng hợp. Tối ưu hóa phân vùng và định dạng giúp các bước xử lý nhanh hơn kỳ vọng. Độ tươi mới dữ liệu duy trì dưới bốn giờ sau khi thị trường đóng cửa nên đáp ứng yêu cầu cung cấp thông tin theo ngày cho người dùng.

Đối với phân hệ hỏi đáp, độ trễ phản hồi chỉ từ hai đến năm giây nên trải nghiệm tương tác gần thời gian thực. Tốc độ này có được nhờ dùng mô hình nhúng gọn nhẹ và chỉ truy xuất một số ít đoạn văn bản làm ngữ cảnh trước khi sinh câu trả lời.

Về độ tin cậy, pipeline vận hành ổn định với khoảng 98 phần trăm lượt chạy hoàn thành mỗi tuần trong giai đoạn thí điểm bốn tuần. Một số lỗi tạm thời do nguồn tin tức không phản hồi đã được Airflow tự động thử lại và khắc phục. Toàn bộ lô dữ liệu vượt qua kiểm thử chất lượng ở mức 100 phần trăm. Hệ thống chưa phải kích hoạt kế hoạch khôi phục thảm họa. Cơ chế sao lưu đa vùng và versioning đã được cấu hình để đáp ứng mục tiêu RPO và RTO đã công bố.

4.2 Phân tích kết quả và nhận xét

Các kết quả xác nhận hiệu quả của kiến trúc Lakehouse hợp nhất trong xử lý dữ liệu tài chính dị thể với quy mô lớn. Thay vì vận hành riêng một kho dữ liệu giao dịch và một hồ dữ liệu tin tức, việc hợp nhất trong Lakehouse giúp đơn giản hóa quản trị nhưng vẫn giữ được khả năng truy vấn phân tích phức tạp với độ trễ thấp. Truy vấn trực tiếp dữ liệu Parquet nén trên S3 thông qua Athena cho thời gian phản hồi tương tác chỉ vài giây đối với các câu hỏi kết hợp giá và chỉ số cảm xúc theo khoảng thời gian. Quan sát này phù hợp với lập luận của Armbrust et al. (2021) về khả năng cân bằng hiệu năng và linh hoạt của Lakehouse.

Phân hệ RAG chứng minh năng lực cung cấp thông tin tài chính có căn cứ xác thực bằng tiếng Việt. Người dùng có thể đặt câu hỏi và nhận câu trả lời súc tích kèm nguồn trích dẫn rõ ràng, giảm tải việc đọc và tổng hợp thủ công. Việc tích hợp RAG giúp hạn chế hiện tượng bịa thông tin. Trong thí điểm, không ghi nhận trường hợp sai lệch nghiêm trọng do câu trả lời luôn dựa vào nguồn đã kiểm chứng trong kho dữ liệu. Kết quả phù hợp với nhận định của Iaroshev et al. (2024) về việc RAG cải thiện độ chính xác và độ tin cậy trong hỏi đáp trên báo cáo tài chính, đồng thời tương thích với bằng chứng của Choe et al. (2025) về lợi ích của truy hồi phân cấp và xếp hạng lại nhiều tầng.


Từ góc độ nghiệp vụ, AEGIS Lumina hoạt động như một môi trường phân tích hợp nhất. Chatbot đóng vai trò trợ lý ảo, hỗ trợ tra cứu số liệu, diễn giải diễn biến và tóm tắt theo chủ đề kèm nguồn cụ thể để người dùng kiểm chứng nhanh. Dashboard tương tác trên lớp Gold cung cấp cái nhìn toàn cảnh về bề rộng thị trường, tương quan ngành ngân hàng với VN-Index và xu hướng chỉ số cảm xúc theo thời gian. Hệ thống có thể phát hiện tín hiệu rủi ro sớm khi xuất hiện dồn dập tin tức tiêu cực, từ đó hỗ trợ điều chỉnh danh mục hoặc truyền thông kịp thời. Với dữ liệu được cập nhật liên tục và gần thời gian

thực, quyết định quản trị có thể dựa trên thông tin mới nhất.

4.3 Khuyến nghị và cải thiện

Dựa trên kết quả thí điểm, nhóm đề xuất các hướng mở rộng sau. Thứ nhất, với RAG, cần xem xét triển khai truy hồi phân cấp kết hợp xếp hạng lại nhiều tầng như gợi ý của Choe et al. (2025) để giảm trùng lặp bằng chứng và tăng mức bao phủ thông tin khi dữ liệu mở rộng. Thứ hai, có thể bổ sung lớp kiểm tra hậu sinh để đối chiếu con số trong câu trả lời với bằng chứng đã truy hồi nhằm nâng cao tính chính xác trong các truy vấn nhạy cảm. Thứ ba, về nghiệp vụ, có thể phát triển mô đun lọc tài sản dựa trên bảng Gold và bổ sung tính năng dự báo ngắn hạn tận dụng kho dữ liệu lịch sử trong Lakehouse. Cuối cùng, các tín hiệu như chỉ số cảm xúc cần được lồng vào quy trình ra quyết định nhưng vẫn duy trì bước kiểm chứng của chuyên gia cho các quyết định quan trọng.

4.4 Ứng dụng triển khai AEGIS Lumina App



Ảnh 7. Kiến trúc tổng quan webservices (Link:

<https://drive.google.com/file/d/1uQnjqLNF4WKxYEF2JJpr3Pfi68xlm5Za/view?usp=sharing>)

Sản phẩm đã được đóng gói thành ứng dụng web với kiến trúc tách biệt frontend và backend. Frontend dùng React 18 và TypeScript, hỗ trợ hiển thị Markdown, hỗ trợ đa ngôn ngữ cho Tiếng Việt và Tiếng anh, bảng biểu và trích dẫn nguồn dưới dạng siêu liên kết. Các trang chính gồm trang Chatbot hỏi đáp, trang Dashboard hiển thị biểu đồ và chỉ số phân tích, và trang Tra cứu Tài sản để lọc cổ phiếu theo tiêu chí dựa trên dữ liệu Gold.

Backend sử dụng FastAPI và kiến trúc Microservices để cung cấp API cho frontend. Các đầu cuối gồm truy vấn dữ liệu dashboard qua Athena và gửi câu hỏi cho pipeline RAG. API thiết kế bất đồng bộ để xử lý đồng thời nhiều yêu cầu và tích hợp cơ chế bộ nhớ đệm cho truy vấn lặp nhằm cải thiện tốc độ phản hồi. Lớp phân quyền cơ bản phân tách truy cập dữ liệu thô cho quản trị nội bộ và truy cập chatbot cho người dùng ứng dụng.

Hiện ứng dụng được triển khai nội bộ trên hạ tầng AWS của doanh nghiệp do tính nhạy cảm của dữ liệu tài chính. Giao diện và chức năng đã sẵn sàng để phát hành dưới dạng dịch vụ khi có yêu cầu. Hình minh họa giao diện chính thể hiện trang Chatbot với ví dụ truy vấn và câu trả lời kèm trích dẫn nguồn.

5. Kết luận

5.1 Kết luận tổng quát

Dự án AEGIS Lumina chứng minh tính khả thi và hiệu quả của việc kết hợp kiến trúc Data Lakehouse ba lớp với hệ thống hỏi đáp tăng cường truy hồi RAG trong bối cảnh phân tích tài chính tại Việt Nam. Về kiến trúc dữ liệu, Lakehouse hợp nhất và quản trị tốt các nguồn dữ liệu phong phú và dị thể của ngành tài chính, từ dữ liệu thị trường đến văn bản phi cấu trúc, đồng thời cho phép truy vấn phân tích nhanh trên toàn bộ tập dữ liệu. Về ứng dụng AI, RAG nâng mức tin cậy khi tương tác giữa mô hình ngôn ngữ lớn và người dùng nhờ luôn gắn với bằng chứng cụ thể. Hệ thống đạt mục tiêu về độ trễ xử lý, mức cập nhật kịp thời và phản hồi chính xác có trích dẫn, qua đó hỗ trợ nâng cao chất lượng phân tích và ra quyết định dựa trên dữ liệu.

5.2 Đóng góp và ưu điểm nổi bật

- (1) Xây dựng thành công pipeline dữ liệu thống nhất từ thu thập đến phục vụ, vận hành tự động và dễ mở rộng. Tổ chức dữ liệu theo tầng Bronze–Silver–Gold cùng các ràng buộc chất lượng giúp đầu ra luôn sạch và sẵn sàng cho nhiều bài toán BI và ML.
- (2) Hình thành các bảng dữ liệu Gold giàu đặc trưng kết hợp tín hiệu kỹ thuật, vĩ mô và tâm lý, tạo tài sản dữ liệu có giá trị cho doanh nghiệp, có thể tái sử dụng cho dự báo, gợi ý và phân tích chuyên sâu.

(3) Tích hợp thành công phân hệ RAG chatbot tiếng Việt trong bối cảnh tài chính nội địa, cung cấp hỏi đáp tự động với độ tin cậy cao. Thực nghiệm cho thấy RAG giảm rõ rệt hiện tượng sinh thông tin sai, vốn là rào cản khi áp dụng LLM trong tài chính [5].

(4) Thiết kế chú trọng bền vững và bảo mật với khả năng phục hồi thảm họa tốt RPO ≤ 24 giờ và RTO ≤ 4 giờ nhờ sao lưu liên vùng và versioning dữ liệu, đồng thời tuân thủ mã hóa và kiểm soát truy cập chặt chẽ, không thu thập PII. Các yếu tố này tạo nền tảng triển khai thực tế trong môi trường doanh nghiệp đòi hỏi an toàn thông tin cao.

5.3 Hạn chế và khuyết điểm

(1) Hiệu năng truy xuất vector trong RAG hiện dùng FAISS IndexFlatIP cho độ chính xác tuyệt đối nên độ trễ tìm kiếm tăng gần tuyến tính theo số lượng vector. Khi quy mô văn bản vượt khoảng một trăm nghìn đoạn, thời gian truy hồi có thể tăng đáng kể. Đây là đánh đổi giữa tốc độ và độ chính xác đã được phân tích trong tài liệu FAISS của Douze và cộng sự [3]. Lựa chọn này phù hợp giai đoạn đầu để ưu tiên độ chính xác, nhưng cần cải tiến khi dữ liệu mở rộng.

(2) Hạn chế về mô hình NLP cho sentiment ở tầng Silver do tiếp cận dựa trên từ khóa và quy tắc, độ chính xác còn hạn chế trong ngữ cảnh phức tạp, mỉa mai hoặc đa nghĩa. Việc huấn luyện mô hình ngôn ngữ sâu cho tiếng Việt vượt phạm vi và nguồn lực của đơn vị hiện tại.

(3) Chưa tích hợp module dự báo dùng ML cho giá cổ phiếu hoặc chỉ số dù dữ liệu đã sẵn. Đây là hướng mở rộng tiềm năng nhưng đòi hỏi thời gian nghiên cứu và thử nghiệm bổ sung.

5.4 Định hướng phát triển

(1) Nâng cấp hệ truy hồi cho thời gian thực ở quy mô lớn bằng cách chuyển sang FAISS IVF hoặc HNSW và khai thác GPU để tăng tốc tính toán. Cách tiếp cận này duy trì độ chính xác tổng thể nhờ bước xếp hạng lại, đồng thời đảm bảo thời gian phản hồi phù hợp môi trường realtime.

(2) Tích hợp sẵn các tác tử AI Agent để chatbot chủ động gọi các mô đun phân tích như tính chỉ báo kỹ thuật, so sánh danh mục hoặc tra cứu lịch sử, từ đó mở rộng năng lực hội

thoại tài chính theo ngữ cảnh.

(3) Mở rộng năng lực phân tích thời gian thực real-time analyst thông qua pipeline xử lý dữ liệu dòng từ thị trường như giá và tin tức bằng Apache Kafka kết hợp Spark Structured Streaming. Hệ thống có thể phát hiện tín hiệu và phát cảnh báo tức thời, hỗ trợ quyết định mang tính thời điểm.

Tổng thể, lộ trình trên đưa AEGIS Lumina tiến hóa thành một nền tảng big data chuyên biệt cho tài chính, kết hợp ba năng lực cốt lõi là lưu trữ và phân tích dữ liệu quy mô lớn, tương tác AI thông minh và phản ứng theo thời gian thực. Nền tảng này đáp ứng toàn diện nhu cầu phân tích, ra quyết định và giao tiếp tự động trong môi trường tài chính số hiện đại.

Danh mục tài liệu tham khảo

Armbrust, M., Ghodsi, A., Xin, R. S., & Zaharia, M. (2021). *Lakehouse: A new generation of open platforms that unify data warehousing and advanced analytics*. Conference on Innovative Data Systems Research (CIDR). (Tài liệu trình bày tầm nhìn kiến trúc Lakehouse hợp nhất Data Warehouse và Data Lake).

Choe, J., Lee, S., Park, J., & Kim, G. (2025). *Hierarchical retrieval with evidence curation for open-domain financial question answering on standardized documents*. Findings of the Association for Computational Linguistics: ACL 2025, 16663–16681. (Nghiên cứu đề xuất truy hồi phân cấp và chọn lọc bằng chứng để cải thiện hỏi-đáp tài chính).

Douze, M., Guzhva, A., Deng, C., Johnson, J., Szilágyi, G., Mazaré, P.-E., Hosseini, L., Lomeli, M., & Jégou, H. (2024). *The Faiss library*. arXiv Preprint arXiv:2401.08281. (Bài báo kỹ thuật mô tả thư viện FAISS cho tìm kiếm vector hiệu năng cao và các kỹ thuật chỉ mục).

Harby, A. A., & Zulkernine, F. (2025). *Data lakehouse: A survey and experimental study*. Information Systems, 127, 102460. <https://doi.org/10.1016/j.is.2024.102460> (Bài khảo sát và thực nghiệm về kiến trúc Data Lakehouse và so sánh với các mô hình dữ liệu khác).

Iaroshev, I., Pillai, R., Vaglietti, L., & Hanne, T. (2024). *Evaluating retrieval-*

augmented generation models for financial report question answering. Applied Sciences, 14(20), 9318. <https://www.mdpi.com/2076-3417/14/20/9318> (Nghiên cứu đánh giá hiệu năng của mô hình RAG trong bài toán hỏi-đáp báo cáo tài chính).